```
                        ┌──────────────┐
                        │   P crven    │
                        └──────┬───────┘
                ┌──────────────┴──────────────┐
        ┌───────┴───────┐            ┌─────────┴─────────┐
        │    U crn      │            │     U crven       │
        └───────┬───────┘            │     (2→1)         │
                │                    │  promjena boja    │
                │                    └───────────────────┘
  ┌─────────┬───┴─────┬─────────┬─────────┐
```

| N lijevo od P
P lijevo od G
(4)
rotacija
+zamjena boja | N lijevo od P
P desno od G
(3→4)
rotacija | N desno od P
P lijevo od G
(3→4)
rotacija | N desno od P
P desno od G
(4)
rotacija
+zamjena boja |

```
                        ┌──────────────┐
                        │      N       │
                        │  dvostruko   │
                        │     crn      │
                        └──────┬───────┘
                ┌──────────────┴──────────────┐
        ┌───────┴───────┐            ┌─────────┴─────────┐
        │    S crn      │            │     S crven       │
        └───────┬───────┘            │   (1 → 2,3,4)     │
                │                    │   zamjena boja    │
                │                    │   + rotacija      │
                │                    └───────────────────┘
  ┌─────────┬───┴─────┬─────────┬─────────┐
```

| SL crn
SR crn
(2 → 1)
oduzimanje crnog | SL crn
SR crven
(4)
rotacija
+ zamjena boja
+promjena boje | SL crven
SR crn
(3 → 4)
rotacija
+ zamjena boja | SL crven
SR crven
(4)
rotacija
+ zamjena boja
+promjena boje |

<u>Rješavanje sustava $\mathbf{Ax} = \mathbf{b}, \quad \mathbf{A} \in \mathrm{R}^{m \times n}$</u>

desni pseudoinverz $= \mathbf{A}^{\mathrm{T}}\left(\mathbf{AA}^{\mathrm{T}}\right)^{-1} \qquad ; \quad m < n$

lijevi pseudoinverz $= \left(\mathbf{A}^{\mathrm{T}}\mathbf{A}\right)^{-1}\mathbf{A}^{\mathrm{T}} \qquad ; \quad m \geq n$

Kaczmarzov algoritam: $\quad \mathbf{w}^{(k+1)} = \mathbf{w}^{(k)} - \mu \dfrac{e^{(k)}\mathbf{x}_{\mathrm{d},R(k)+1}}{\left\|\mathbf{x}_{\mathrm{d},R(k)+1}\right\|^{2}}$,

gdje su: $\qquad \mathbf{w}^{(0)} = \mathbf{0}, \qquad 0 < \mu < 2$

$$e^{(k)} = \mathbf{x}_{\mathrm{d},R(k)+1}^{\mathrm{T}}\mathbf{w}^{(k)} - y_{\mathrm{d},R(k)+1}$$

ili $\qquad e^{(k)} = f\left(\mathbf{x}_{\mathrm{d},R(k)+1}^{\mathrm{T}}\mathbf{w}^{(k)}\right) - y_{\mathrm{d},R(k)+1}$.

<u>Gradijentna metoda optimizacije</u>

$$f(\mathbf{x}) \quad , \qquad f : \mathrm{R}^{n} \to \mathrm{R}$$
$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \alpha_{k} \cdot \nabla f\left(\mathbf{x}^{(k)}\right)$$

Ciljna funkcija za *Adaline*: $\qquad f(\mathbf{w}) = \dfrac{1}{2}\left\|\mathbf{X}_{\mathrm{d}}^{\mathrm{T}}\mathbf{w} - \mathbf{y}_{\mathrm{d}}\right\|^{2}$

Gradijent ciljne funkcije: $\qquad \nabla f(\mathbf{w}) = \mathbf{X}_{\mathrm{d}}\left(\mathbf{X}_{\mathrm{d}}^{\mathrm{T}} \cdot \mathbf{w} - \mathbf{y}_{\mathrm{d}}\right)$

$$\Downarrow$$

Iteracija: $\quad \mathbf{w}^{(k+1)} = \mathbf{w}^{(k)} - \alpha_{k} \cdot \mathbf{X}_{\mathrm{d}} \cdot \mathrm{e}^{(k)}$,

gdje je $\qquad \mathrm{e}^{(k)} = \mathbf{X}_{\mathrm{d}}^{\mathrm{T}} \cdot \mathbf{w}^{(k)} - \mathbf{y}_{\mathrm{d}}$.

Prolazak prema naprijed matrično

$$\mathbf{v} = \mathbf{W}^h \cdot \mathbf{x} - \boldsymbol{\theta}^h \qquad \qquad \mathbf{z} = sigmoid\,(\mathbf{v})$$

$$\mathbf{u} = \mathbf{W}^o \cdot \mathbf{z} - \boldsymbol{\theta}^o \qquad \qquad \mathbf{y} = sigmoid\,(\mathbf{u})$$

Rasprostiranje unatrag matrično

$$\mathbf{EA}^o = \mathbf{y} - \mathbf{y}_d$$

$$\mathbf{EI}^o = \mathbf{EA}^o .* \mathbf{y} .* (\mathbf{1} - \mathbf{y})$$

.* = množenje po parovima, a ne matrično!

$$\boldsymbol{\delta}^o = \mathbf{EI}^o$$

$$\mathbf{EW}^o = \boldsymbol{\delta}^o \cdot \mathbf{z}^T = \mathbf{EI}^o \cdot \mathbf{z}^T$$

$$\mathbf{EA}^h = (\mathbf{w}^o)^T \cdot \mathbf{EI}^o$$

.* = množenje po parovima, a ne matrično!

$$\mathbf{EI}^h = \mathbf{EA}^h .* \mathbf{z} .* (\mathbf{1} - \mathbf{z})$$

$$\boldsymbol{\delta}^h = \mathbf{EI}^h$$

$$\mathbf{EW}^h = \boldsymbol{\delta}^h \cdot \mathbf{x}^T = \mathbf{EI}^h \cdot \mathbf{x}^T$$

$$\mathbf{E\Theta}^o = -\mathbf{EI}^o \qquad \qquad \mathbf{E\Theta}^h = -\mathbf{EI}^h$$

Stožerni razvoj oko (p,q)

$$y_{ij}' = y_{ij} - \frac{y_{iq}}{y_{pq}}\, y_{pj} \qquad ; \quad i \neq p$$

$$y_{pj}' = \frac{y_{pj}}{y_{pq}}$$